

SUPSI

Classificazione di stili di danza da video

Studente/i

Galdiolo Giada

Relatore

Giusti Alessandro

Correlatore

-

Committente

-

Corso di laurea

Ingegneria informatica

Codice progetto

C11352

Anno

2025/2026

Data

26/08/2026

STUDENTSUPSI

*Alla mia famiglia,
punto fermo della mia vita,
ai vostri sacrifici, ai vostri insegnamenti e al vostro sostegno.*

*A Mattia,
mi baile inolvidable,
alla forza che mi trasmetti, all'amore che mi regali.*

*A me stessa,
il mio giudice più severo,
alle mie paure, ai miei sogni, alla costante voglia di migliorarmi.*

Indice

Abstract	9
Uso di intelligenza artificiale generativa	11
1. Introduzione	12
2. Stato dell'arte	14
2.1 Generazione di coreografie	14
2.2 Valutazione della qualità del movimento	15
2.3 Classificazione dello stile di danza	15
2.3.1 Riconoscimento tramite sliding window	15
2.3.2 Riconoscimento tramite segmentazione	16
2.3.3 Riconoscimento tramite feature interpretabili e confronto con la percezione umana	17
2.4 Dataset di supporto	17
2.5 Conclusione	17
3. Dataset	18
3.1 AIST++	18
3.2 Dataset YouTube	20
3.3 Registrazioni in tempo reale	20
3.4 Conclusione	20
4. Estrazione dei keypoints	21
4.1 Scelta dello strumento di pose estimation	21
4.2 Pipeline di estrazione	21
4.3 Conclusione	23
5. Estrazione delle feature	24
5.1 Normalizzazione dei keypoints	24
5.2 Feature ispirate alla Laban Movement Analysis	24
5.2.1 Body	25
5.2.2 Shape	25
5.2.3 Effort	26
5.2.4 Space	27
5.3 Conclusione	27
6. Addestramento e analisi dei risultati	28
6.1 Pipeline di training	28
6.2 Analisi dei risultati	28
6.2.1 Metriche sul test set di AIST++	28
6.2.2 Generalizzazione sul dataset YouTube	29
6.2.3 Interpretabilità tramite SHAP	30
6.3 Conclusione	31
7. Sistema di riconoscimento in tempo reale	32
7.1 Panoramica del sistema	32
7.2 Architettura	32

7.3 Metronomo e riproduzione musicale	33
7.4 Conclusione	33
8. Sostenibilità computazionale.....	34
8.1 Il costo di una singola sessione.....	34
8.2 Il costo dell'addestramento.....	34
8.3 Confronto tra video intero e segmentazione.....	35
8.4 Conclusione	36
Conclusioni.....	37
Sviluppi futuri	37
Bibliografia	38

Indice delle figure

Figura 1 e 2: Roberto Bolle danza con un braccio meccanico nella trasmissione "Danza con Me", 2019	12
Figura 3: Panoramica della pipeline di classificazione. Dal video vengono estratti i frame, da cui un modello di pose estimation stima i keypoints del corpo. Questi vengono normalizzati e trasformati in un insieme di feature ispirate alla Laban Movement Analysis, classificate da un modello Random Forest.....	13
Figura 4: Esempi di coreografie generate da Bailando	14
Figura 5: Quattro coreografie diverse generate da FACT a partire dalla stessa sequenza iniziale, cambiando solo la base musicale.....	15
Figura 6: In EDGE l'utente vincola frame o articolazioni specifiche (in verde/beige), e il modello genera il resto della coreografia (in blu/grigio) coerente con quei vincoli	15
Figura 7: Effetto dell'ampiezza della finestra temporale sull'accuratezza	16
Figura 8: Schema del metodo di segmentazione e voto di maggioranza adottato da Hamscher et al. e ripreso in questo lavoro nel confronto con l'approccio a video intero (Capitolo 8.3).....	16
Figura 9: Interfaccia dello studio sulla percezione umana di Baker et al.: una sequenza di danza mostrata come scheletro semplificato e i dieci stili tra cui scegliere.	17
Figura 10: Disposizione delle 9 telecamere attorno al ballerino	18
Figura 11: Esempi di frame di diversi stili di danza dal dataset AIST.....	18
Figura 12, 13 e 14: Esempi di frame dal dataset YouTube	20
Figura 15 e 16: Due frame tratti dalle registrazioni in tempo reale.....	20
Figura 17 e 18: A sinistra lo schema dei 17 keypoints COCO, a destra lo schema dei 33 keypoints del formato utilizzato da MediaPipe.....	21
Figura 19 e 20: A sinistra un frame originale di un video; a destra lo stesso frame rappresentato tramite i keypoints estratti e lo scheletro ricostruito.	22
Figura 21 e 22: A sinistra un frame di un video; a destra lo stesso frame con disegnata la traiettoria della mano	22
Figura 23 e 24: Sovrapposizione dei keypoints e dello scheletro al video	22
Figura 25: Confronto prima e dopo la normalizzazione	24
Figura 26: Distanza del polso destro e della caviglia sinistra dal centro del bacino nel tempo, con i segmenti corrispondenti disegnati sullo scheletro e media indicata nel grafico	25
Figura 27: Area del corpo nel tempo, con il bounding box dei 12 giunti evidenziato sullo scheletro e media e massimo indicati nel grafico.	26
Figura 28: Angolo del gomito sinistro e destro nel tempo, con i relativi archi disegnati sullo scheletro, alla base del calcolo degli istogrammi.....	26

Figura 29: Velocità dei polsi nel tempo, con i polsi evidenziati sullo scheletro e la mediana indicata nel grafico	27
Figura 30: Velocità del centro del bacino nel tempo, con i fianchi evidenziati sullo scheletro e la mediana indicata nel grafico.....	27
Figura 31: Confusion matrix delle 10 classi sul test set AIST++	29
Figura 32: Impatto e contributo delle prime 10 feature alle previsioni del modello	30
Figura 33: valori SHAP che illustrano il contributo delle feature alle previsioni del modello per lo stile Middle Hip-Hop	30
Figura 34: Valori SHAP che illustrano il contributo delle feature alle previsioni del modello per lo stile Street Jazz.....	31
Figura 35: Le fasi del sistema di riconoscimento in tempo reale, con la durata approssimativa di ciascuna.....	32
Figura 36: Interfaccia del sistema durante la Fase 1 (cattura + elaborazione), a 7,8 dei 10 secondi di registrazione. Lo scheletro estratto dai keypoint è sovrapposto al video originale; le due barre in basso mostrano i frame ancora in coda (40) e quelli già elaborati (128)	33
Figura 37: Pipeline per un video di 10 secondi.....	34
Figura 38: Pipeline di training.....	35
Figura 39: Confronto tempo/energia/CO2 e scatter energia-accuratezza tra le due varianti.	36

Indice delle tabelle

Tabella 1: Generi di danza presenti in AIST++, con sigla e breve descrizione	19
Tabella 2: Precision, recall e F1 per stile sul dataset AIST++	28
Tabella 3: Precision, recall e F1 per stile sul dataset YouTube	29

Abstract

Il riconoscimento automatico dello stile di danza da video si colloca tra pose estimation, analisi del movimento e classificazione, un compito reso complesso dal fatto che stili diversi differiscono non solo nelle pose assunte, ma anche e soprattutto nella dinamica con cui il movimento viene eseguito. Questo lavoro presenta un sistema che classifica lo stile di danza a partire da keypoints bidimensionali estratti da video tramite MMPose, utilizzando un insieme di feature interpretabili ispirate alla Laban Movement Analysis (LMA), organizzate nelle quattro categorie Body, Effort, Shape e Space, classificate con un modello Random Forest.

Il sistema è stato addestrato e valutato sul dataset AIST++ (10 stili di danza, oltre 1400 sequenze), raggiungendo un'accuratezza dell'89,72% (Top-3: 100%) sul test set interno. La capacità di generalizzare in condizioni di ripresa non controllate è stata valutata su un insieme di video YouTube mai visti in addestramento, osservando un calo di accuratezza marcato e disomogeneo tra stili, un pattern coerente con quanto riportato dai lavori più direttamente comparabili in letteratura. Un'analisi di interpretabilità tramite SHAP ha mostrato che le feature con il maggiore impatto sulle decisioni del modello appartengono prevalentemente alle categorie Effort e Body.

Il sistema è stato inoltre integrato in un'applicazione dimostrativa in tempo reale, in grado di riconoscere lo stile di un ballerino dal vivo tramite webcam e avviare automaticamente un brano musicale coerente con lo stile riconosciuto. Infine, è stato analizzato il costo computazionale e ambientale di una specifica scelta metodologica, il confronto tra classificazione a video intero e a segmenti, misurato tramite la libreria CodeCarbon: la segmentazione produce un guadagno di accuratezza marginale a fronte di un costo energetico circa triplo, motivando la scelta del video intero come configurazione finale.

Abstract

Automatically recognizing dance style from video sits at the intersection of pose estimation, movement analysis, and classification, a task made challenging by the fact that different styles often differ not only in body configurations, but also in the dynamics with which movement is executed. This work presents a system that classifies dance style from two-dimensional keypoints extracted from video using MMPose, based on a set of interpretable features inspired by Laban Movement Analysis (LMA), organized into the four categories Body, Effort, Shape, and Space, and classified with a Random Forest model.

The system was trained and evaluated on the AIST++ dataset (10 dance styles, over 1,400 sequences), reaching 89.72% accuracy (Top-3: 100%) on the internal test set. Its ability to generalize to uncontrolled recording conditions was assessed on a set of YouTube videos never seen during training, revealing a marked and style-dependent drop in accuracy, a pattern consistent with findings reported by the most directly comparable works in the literature. A SHAP-based interpretability analysis showed that the features with the greatest impact on the model's decisions predominantly belong to the Effort and Body categories.

The system was further integrated into a real-time demonstration application, able to recognize a dancer's style live via webcam and automatically play a matching music track. Finally, the computational and environmental cost of a specific methodological choice, whole-video versus segment-based classification, was analyzed using the CodeCarbon library: segmentation yields a marginal accuracy gain at roughly three times the energy cost, motivating the choice of whole-video classification as the final configuration.

Uso di intelligenza artificiale generativa

Durante lo svolgimento di questo progetto è stato utilizzato un assistente basato su intelligenza artificiale generativa (Claude, Anthropic) come supporto in specifiche fasi del lavoro. Nella fase di implementazione, l'assistente è stato utilizzato per il debug di codice Python, in particolare per la diagnosi di problemi di installazione dell'ambiente di sviluppo e di compatibilità tra versioni di librerie, e per fornire una traccia iniziale per funzioni di supporto come gli script di visualizzazione. L'intero codice è stato in ogni caso sottoposto ad analisi e rielaborazione personale; l'autrice ha verificato, modificato e validato ogni singola istruzione, assumendosi la piena responsabilità tecnica e concettuale della versione finale.

In merito alla stesura del presente documento, l'intelligenza artificiale è stata impiegata esclusivamente come strumento di supporto alla revisione linguistica e al miglioramento della fluidità espositiva. Tutti i contenuti, i concetti teorici, le deduzioni logiche e le analisi critiche presentate sono frutto esclusivo del lavoro e dell'elaborazione originale dell'autrice.

1. Introduzione

Negli ultimi anni il volume di contenuti video legati alla danza pubblicati su Internet è cresciuto in modo marcato, sia sotto forma di performance professionali sia di contenuti amatoriali. Poter classificare automaticamente lo stile di danza rappresentato in un video ha un'utilità pratica concreta in questo contesto: facilita l'organizzazione e la ricerca all'interno di archivi di contenuti, può supportare compagnie di danza, insegnanti e ricercatori del movimento nell'indicizzare e recuperare materiale video in base allo stile eseguito, un'operazione oggi affidata quasi interamente all'etichettatura manuale.

La scelta di affrontare questo problema nasce da un interesse personale sia per la danza sia per il machine learning, e in particolare per l'intersezione tra i due. L'idea iniziale era in realtà orientata verso un problema diverso: la generazione di coreografie a partire dalla musica. Tuttavia, questo ambito si è rivelato troppo complesso per essere affrontato in modo solido nell'ambito di una tesi di Bachelor, sia per le risorse computazionali richieste sia per la maturità metodologica necessaria a lavorare con i modelli generativi esistenti in questo campo. La scelta è quindi ricaduta sulla classificazione dello stile, un problema che permette di esplorare la stessa intersezione tra machine learning e danza con un ambito più contenuto e adatto al contesto di questo lavoro. Un'immagine efficace di questa intersezione è quella di Roberto Bolle che danza con un braccio meccanico (Danza con Me, 2019), pensata dal ballerino come una riflessione sul rapporto tra arte e tecnologia: un esempio di come i sistemi tecnologici possano mettersi al servizio dell'arte, anziché sostituirla o esserle estranei. Questo lavoro si muove in una direzione simile: applica strumenti computazionali all'analisi del movimento non per sostituire l'espressività del gesto umano, ma per descriverne le dinamiche in modo più sistematico e quantitativo.



Figura 1 e 2: Roberto Bolle danza con un braccio meccanico nella trasmissione "Danza con Me", 2019

Un aspetto da sottolineare è che gli stili di danza analizzati in questo lavoro appartengono tutti ad un unico genere più ampio, chiamato street dance. Il dataset AIST Dance Video Database [1], da cui deriva il dataset di addestramento utilizzato in questo lavoro, divide questo genere in due famiglie, quella Old School (Break, Pop, Lock, Waack), sviluppatesi tra gli anni '70 e '90, e quella New School (Middle Hip-hop, LA-style Hip-hop, House, Krump, Street Jazz, Ballet Jazz), affermatesi a partire dagli anni '90, a loro volta suddivise nei dieci stili specifici utilizzati in questo lavoro.

Distinguere questi stili non è un compito semplice nemmeno per un osservatore umano. Baker et al. [2] (discusso più in dettaglio nel capitolo 2) hanno condotto un esperimento online in cui a diversi soggetti venivano mostrate sequenze di danza tratte dallo stesso dataset AIST++ [3] utilizzato in questo lavoro, chiedendo di identificarne lo stile: gli autori riportano che in alcuni casi le persone sono state in grado di riconoscere rapidamente lo stile di una sequenza, ma che questa capacità varia considerevolmente in base all'esperienza dell'osservatore e allo stile specifico considerato.

Questa difficoltà non è casuale: il problema non è riducibile a un insieme di regole codificabili a priori, ma è piuttosto un problema di pattern recognition, in cui le differenze tra stili emergono da tendenze ricorrenti nel movimento, non da misure geometriche precise. Una parte della difficoltà è forse relativamente accessibile: stili diversi tendono a privilegiare pose diverse. Una parte più sottile riguarda invece la dinamica con cui il movimento viene eseguito, la velocità, l'energia e la fluidità con le quali si passa da una posa all'altra. È proprio su questo aspetto che si concentra la Laban Movement Analysis: a differenza di una descrizione puramente geometrica della posa, la LMA offre un vocabolario per descrivere la qualità con cui il movimento si sviluppa nel tempo, la sua energia, il modo in cui il corpo occupa lo spazio, la forma che assume durante il movimento; è questo il motivo per cui il presente lavoro costruisce le proprie feature attorno a questo framework.

Un elemento che caratterizza ciascuno stile di danza è il legame con un genere musicale specifico. Il Locking e il Popping si sono sviluppati insieme al funk; il Waacking con la musica disco degli anni '70; l'House dance è nata a stretto contatto con la musica house di Chicago e New York; il Krump, pur non avendo un genere musicale proprio in senso stretto, si accompagna tipicamente a un ritmo aggressivo, coerente con l'energia esplosiva dello stile. Nel sistema di riconoscimento in tempo reale sviluppato in questo lavoro (descritto nel capitolo 7), lo stile riconosciuto determina automaticamente l'avvio di un brano coerente con il genere musicale associato.

L'obiettivo di questo progetto è sviluppare un sistema che riconosca lo stile di danza a partire da un video, tramite pose estimation 2D e un insieme di feature ispirate alla Laban Movement Analysis, classificate con un modello Random Forest. Più nel dettaglio, il lavoro si propone di: costruire una pipeline di classificazione basata su feature interpretabili; valutarne le prestazioni non solo in condizioni controllate ma anche su dati acquisiti in condizioni reali; integrare il sistema in un'applicazione dimostrativa in tempo reale, in grado di riconoscere lo stile di un ballerino dal vivo tramite webcam; e analizzare, oltre alle prestazioni predittive, anche il costo computazionale e ambientale di alcune scelte adottate lungo il percorso. Pur concentrandosi sulla danza, le tecniche impiegate non sono specifiche di questo dominio, e si applicano naturalmente ad altri ambiti in cui l'oggetto di analisi è il movimento del corpo umano.




Figura 3: Panoramica della pipeline di classificazione. Dal video vengono estratti i frame, da cui un modello di pose estimation stima i keypoints del corpo. Questi vengono normalizzati e trasformati in un insieme di feature ispirate alla Laban Movement Analysis, classificate da un modello Random Forest.

2. Stato dell'arte

L'intersezione tra machine learning e danza si sviluppa in più ambiti: ne sono un esempio la generazione di coreografie a partire da una base musicale, la valutazione della qualità o della correttezza tecnica del movimento e la classificazione dello stile di danza, oggetto di questo lavoro. Questo capitolo presenta i contributi più rilevanti in ciascuna di queste direzioni, si concentra in dettaglio sui lavori di classificazione più direttamente comparabili a questo lavoro, e offre una panoramica dei dataset utilizzati in questo ambito di ricerca.

2.1 Generazione di coreografie

Un primo filone di ricerca affronta il problema di generare movimento a partire dalla musica. Li et al. [3] propongono FACT (Full-Attention Cross-modal Transformer), un modello che impara le relazioni tra musica e movimento per generare coreografie 3D coerenti con un brano musicale dato; oltre alla musica, il modello riceve in input anche un breve movimento iniziale, che gli permette di capire quale stile riprodurre (figura 5). Lo stesso lavoro introduce anche il dataset AIST++ utilizzato in questo progetto, rendendo questo paper un riferimento diretto sia per il dataset sia per uno dei primi approcci generativi in questo ambito.

Bailando [4] parte da un'osservazione diversa: non tutti i movimenti del corpo umano sono adatti alla danza. Per questo motivo, il modello costruisce prima un "dizionario" di pose tipiche della danza, da cui pesca in seguito per costruire la coreografia, invece di generare liberamente qualsiasi posizione del corpo. In più, mentre FACT impara solo osservando esempi, Bailando aggiunge anche una fase di "reinforcement learning", in cui il modello viene premiato quando i movimenti generati seguono davvero il ritmo della musica.



Figura 4: Esempi di coreografie generate da Bailando

EDGE [5], il più recente dei tre, funziona in modo diverso: parte da rumore casuale e lo trasforma gradualmente in una sequenza di movimento realistica (un modello di diffusione), invece di generare il movimento direttamente. Si distingue inoltre per la possibilità di modificare solo una parte della coreografia già generata (ad esempio la posizione iniziale o finale), lasciando il resto invariato (Figura 6).

In un confronto diretto tra i tre modelli, condotto tramite un sondaggio online con 147 partecipanti a cui venivano mostrate coppie di clip generate da modelli diversi, EDGE risulta il preferito nella maggioranza dei confronti. Un limite dichiarato dagli stessi autori riguarda le coreografie di lunga durata: il modello genera sequenze di soli 5 secondi alla volta, che vengono poi unite una dopo l'altra, con il rischio che la coerenza del movimento si perda nel passaggio da una sezione alla successiva.




Figura 5: Quattro coreografie diverse generate da FACT a partire dalla stessa sequenza iniziale, cambiando solo la base musicale



Figura 6: In EDGE l'utente vincola frame o articolazioni specifiche (in verde/beige), e il modello genera il resto della coreografia (in blu/grigio) coerente con quei vincoli

2.2 Valutazione della qualità del movimento

Un secondo filone di ricerca si concentra sul valutare quanto un'esecuzione sia tecnicamente corretta rispetto a un riferimento, tipicamente a supporto della didattica della danza. Un esempio recente è il lavoro di Qu [6], che valuta la qualità di un'esecuzione basandosi su tre aspetti: accuratezza, fluidità ed espressività. A differenza degli approcci discussi in questo capitolo, questo lavoro non parte da keypoints, ma direttamente dai frame video: una scelta motivata dagli autori con l'idea che una rappresentazione a soli keypoints rischi di perdere dettagli visivi rilevanti per la qualità del movimento.

2.3 Classificazione dello stile di danza

Il filone più direttamente rilevante per questo lavoro è quello della classificazione dello stile di danza. Tre contributi recenti affrontano questo problema utilizzando keypoints 3D sul dataset AIST++, differendo sia nel tipo di feature estratte sia nel modo in cui introducono l'informazione temporale. I primi due, in particolare, organizzano le proprie feature secondo la Laban Movement Analysis (LMA) [7], un framework sviluppato dal coreografo Rudolf Laban per descrivere in modo sistematico il movimento del corpo umano lungo quattro categorie complementari: Body, Effort, Shape e Space. Lo stesso framework, descritto più in dettaglio nel capitolo 5, è alla base anche delle feature utilizzate in questo lavoro.

2.3.1. Riconoscimento tramite sliding window

Turab et al. [8] estraggono dai keypoints 3D un insieme di feature organizzate nelle quattro componenti della LMA: per Body calcolano distanze euclidee, angoli tra i giunti principali e una misura di initiation per individuare quale giunto avvia il movimento; per Effort calcolano velocità, accelerazione e un indicatore di energia cinetica; per Shape misurano il volume del corpo nello spazio 3D; infine, per Space, valutano traiettorie, curvature e dispersione spaziale.

Per l'informazione temporale, a differenza di calcolare ciascuna feature confrontando solo due frame consecutivi, approccio molto sensibile al rumore, lo fanno su una finestra di alcuni frame che scorre lungo tutta la sequenza: ad esempio, la velocità di un giunto non è la differenza di posizione tra un frame e il successivo, ma quella tra l'inizio e la fine della finestra. Confrontando sistematicamente diverse ampiezze di finestra e due classificatori, Support Vector Machine e Random Forest,

osservano che il miglioramento di accuratezza è marcato tra 5 e 30 frame consecutivi, per poi diventare marginale oltre questa soglia (Figura 7); la configurazione migliore, finestra di 55 frame con Random Forest, raggiunge un'accuratezza del 99,68%.

Un aspetto particolarmente rilevante per questo paper è la loro valutazione su un insieme di video di danza reperiti online, mai visti in addestramento: riportano un calo di accuratezza marcato e fortemente disomogeneo tra stili, da un massimo dell'81,89% (Lock) fino a un minimo del 10,21% (Break). Questo pattern, ovvero un modello che generalizza bene su dati controllati ma peggiora in modo molto diseguale tra stili su dati acquisiti in condizioni diverse, è coerente con quanto osservato anche in questo lavoro, e suggerisce che il problema non sia specifico di un singolo approccio, ma una difficoltà condivisa nell'ambito.




Figura 7: Effetto dell'ampiezza della finestra temporale sull'accuratezza

2.3.2 Riconoscimento tramite segmentazione

Hamscher et al. [9] propongono invece distanze dei giunti dal centro del bacino per la componente Body, distanze incrociate mano-piede per Shape, rotazione angolare del torso rispetto alla telecamera per la componente Space, oltre a velocità e accelerazione per Effort. Aggiungono inoltre un insieme di feature nel dominio della frequenza tramite Fast Fourier Transform (FFT), pensate per catturare la periodicità e le strutture ritmiche del movimento.

Adottano un approccio diverso per introdurre informazione temporale: dividono ciascuna sequenza in un numero fisso di segmenti, calcolano le feature separatamente su ciascun segmento, per poi ricombinare le predizioni con un voto di maggioranza a livello di video (Figura 8). Riportano un'accuratezza crescente da 82,23% con un singolo segmento fino a 94,11% con dieci segmenti, un miglioramento di circa 12 punti percentuali; proseguendo l'ablazione fino a 15 segmenti l'accuratezza sale ulteriormente al 96,35%, per poi stabilizzarsi oltre questa soglia. La scelta di dieci segmenti riflette quindi un compromesso tra accuratezza e numero di feature generate, non il valore che massimizza in assoluto le prestazioni.




Figura 8: Schema del metodo di segmentazione e voto di maggioranza adottato da Hamscher et al. e ripreso in questo lavoro nel confronto con l'approccio a video intero (Capitolo 8.3)

2.3.3 Riconoscimento tramite feature interpretabili e confronto con la percezione umana

Baker et al. [2], diversamente dai due lavori appena citati, introducono un insieme di feature manuali organizzate in quattro categorie: movimento del centro del bacino, movimento delle estremità (polci e caviglie), momento angolare rispetto al centro del bacino, ed "espansione" del corpo, ovvero la distanza media dei giunti dal centro del bacino. Ottengono un'accuratezza del 76%.

L'aspetto più originale del loro lavoro è il confronto diretto con la capacità delle persone di svolgere lo stesso compito: hanno condotto un esperimento online in cui a persone con esperienza nella danza hip-hop venivano mostrate versioni semplificate, a scheletro e senza audio, di sequenze del dataset, chiedendo di identificarne lo stile. I partecipanti hanno raggiunto un'accuratezza del 38%, sensibilmente inferiore a quella del loro modello; gli autori segnalano inoltre, tra i limiti del proprio lavoro, che l'assegnazione delle sequenze del dataset a un singolo stile non è sempre univoca nemmeno per gli esperti consultati.




Figura 9: Interfaccia dello studio sulla percezione umana di Baker et al.: una sequenza di danza mostrata come scheletro semplificato e i dieci stili tra cui scegliere.

2.4 Dataset di supporto

Oltre ad AIST++ [3], discusso in dettaglio nel capitolo 3, la letteratura sulla classificazione e generazione di danza fa riferimento anche ad altri dataset. Il Motorica Dance Dataset [10] copre 8 stili di danza, in parte sovrapposti a quelli di AIST++ (Hip-hop, Krump, Pop, Lock, Jazz) e in parte diversi (Charleston, Tapping, Casual), con 121 clip a 120 fps. L'ImperialDance-Dataset [11] comprende invece 5 stili (Ballet, Hip-hop, Jazz, K-Pop, Urban) su 20 clip, con ballerini di livello di esperienza eterogeneo (esperti, intermedi, principianti), acquisiti a 100 fps. Questi dataset sono utilizzati raramente nella letteratura sulla classificazione perché sensibilmente più piccoli di AIST++.

2.5 Conclusione

I lavori discussi in questo capitolo mostrano come l'intersezione tra machine learning e danza si articoli in direzioni complementari: generare movimento, valutarne la correttezza, riconoscerne lo stile. All'interno di quest'ultimo filone, i tre lavori più direttamente comparabili a questa tesi condividono il dataset AIST++ ma differiscono nella dimensionalità dei dati (3D in tutti e tre i casi, contro la scelta 2D di questo lavoro), nel trattamento del tempo (sliding window, segmentazione, o assente) e nel framework di riferimento per le feature (LMA nei primi due casi, un framework proprio nel terzo). Il capitolo seguente descrive nel dettaglio i dati utilizzati in questo lavoro, a partire dallo stesso dataset AIST++ impiegato in tutti i lavori qui discussi.

3. Dataset

Per l'addestramento e la valutazione del sistema di classificazione sono stati impiegati tre insiemi di dati con ruoli differenti tra loro. Il primo, AIST++ [3], costituisce la base per l'addestramento del modello, essendo un dataset di dimensioni consistenti, etichettato e acquisito in condizioni controllate. Il secondo insieme è composto da video di danza reperiti su YouTube ed è stato usato esclusivamente in fase di test, per verificare quanto il modello riesca a generalizzare a condizioni di ripresa diverse da quelle del dataset di addestramento. Il terzo insieme, infine, raccoglie le registrazioni effettuate tramite il sistema di riconoscimento in tempo reale sviluppato in questo progetto, utili sia per ulteriori verifiche sia per la dimostrazione finale del lavoro.

3.1 AIST++

AIST++ è un dataset di danza costruito a partire da AIST Dance Database [1], una raccolta di video girati con più telecamere, che comprende sia performance da solista sia di gruppo, eseguite da 40 ballerini professionisti. La raccolta di dati di danza annotati è un problema noto in questo ambito di ricerca, poiché richiede ballerini professionisti e uno studio attrezzato con più telecamere sincronizzate, rendendo il processo costoso e difficile da scalare. Gli autori di AIST++ hanno affrontato il problema ricostruendo il movimento tridimensionale a partire dai video multi-vista già disponibili in AIST, creando così un dataset che integra i video originali con le coordinate dei keypoints. Gli Autori di AIST++ hanno tuttavia escluso le sequenze di gruppo poiché la ricostruzione 3D multi-vista diventa sensibilmente più complessa quando più persone sono presenti nella stessa inquadratura.

Il dataset comprende 1408 sequenze di danza suddivise in 10 generi differenti. Ogni sequenza è ripresa da 9 telecamere e la durata dei singoli filmati varia tra 7,4 e 48 secondi. Sebbene gli autori originali propongano due diverse strategie di suddivisione dei dati (una basata sui soggetti e una basata su coreografia e musica), per gli scopi di questo progetto si è optato per una suddivisione personalizzata. Nello specifico, per garantire che nessuna sequenza coreografica utilizzata in fase di validazione sia stata precedentemente vista dal modello durante l'addestramento, la suddivisione tra training set e test set è stata effettuata mediante GroupShuffleSplit, raggruppando le sequenze per genere e numero di coreografia (i dettagli di questa scelta, e perché è necessaria su AIST++, sono discussi nel capitolo 6).




Figura 10: Disposizione delle 9 telecamere attorno al ballerino



Figura 11: Esempi di frame di diversi stili di danza dal dataset AIST

I dati principali sono forniti in formato Python pickle e organizzati in diverse cartelle a seconda del tipo di informazione contenuta. La cartella motions contiene la posa ricostruita secondo il modello parametrico del corpo umano SMPL (Skinned Multi-Person Linear Model) [12]. Le cartelle keypoints3d e keypoints2d contengono rispettivamente le coordinate tridimensionali e bidimensionali dei keypoints, queste ultime secondo lo schema COCO a 17 giunti [13], insieme ai relativi punteggi di confidenza e ai timestamp di ogni frame. Oltre a questi dati, vengono inoltre forniti i parametri di calibrazione delle telecamere e un elenco delle sequenze da escludere perché ricostruite in modo poco affidabile.

Il nome di ciascun file identifica in modo univoco la sequenza a cui si riferisce, ad esempio gBR_sBM_c01_d04_mBR0_ch01: i singoli segmenti codificano rispettivamente il genere di danza, la modalità di ripresa, l'identificativo della telecamera, l'identificativo del ballerino, il brano musicale utilizzato e la coreografia. I 10 generi di danza presenti nel dataset sono riportati in Tabella 1. Dal dataset sono state escluse le sequenze acquisite con telecamera in movimento, identificate dal codice SMM nel nome del file. Questo accorgimento è necessario perché il modello non è in grado di distinguere il movimento della telecamera dal movimento reale del ballerino.

Per questo lavoro si è scelto di utilizzare la rappresentazione a keypoints bidimensionali, scartando i dati 3D e le rappresentazioni SMPL. La scelta è motivata dalla necessità che il sistema sviluppato sia in grado di elaborare video generici, sia acquisiti da YouTube sia ripresi dal vivo con una singola telecamera, per i quali non è disponibile alcuna ricostruzione tridimensionale.

Sigla	Genere	Descrizione
gBR	Break	Stile acrobatico nato a New York negli anni '70, caratterizzato da movimenti a terra
gHO	House	Nato nella scena della musica house di Chicago e New York, basato su passi veloci e un movimento continuo di tutto il corpo
gJB	Ballet Jazz	Variante del jazz influenzata dalla danza classica, con movimenti precisi e ben definiti
gJS	Street Jazz	Variante del jazz più energica e vicina alla danza urbana, meno formale del Ballet Jazz
gKR	Krump	Nato a Los Angeles nei primi anni 2000, basato su movimenti bruschi e intensi di braccia e petto
gLH	LA style Hip-hop	Stile coreografato, nato negli studi di danza, con un'estetica vicina al jazz e un forte legame con il testo della canzone
gLO	Lock	Creato a Los Angeles nel 1970, caratterizzato da improvvisi blocchi del movimento ("lock") alternati a fasi fluide
gMH	Middle Hip-hop	Stile hip-hop più vicino alla tradizione freestyle
gPO	Pop	Nato nella scena funk californiana a metà degli anni '70, basato su contrazioni muscolari che danno l'impressione di uno scatto
gWA	Waack	Nato nei club di Los Angeles negli anni '70, caratterizzato da ampi movimenti rotatori delle braccia

Tabella 1: Generi di danza presenti in AIST++, con sigla e breve descrizione

3.2 Dataset YouTube

Per verificare la capacità di generalizzazione del modello oltre le condizioni controllate del dataset di addestramento, è stato raccolto un secondo insieme di dati a partire da video di danza pubblicati su YouTube. Questi video presentano condizioni di ripresa più eterogenee rispetto ad AIST++: telecamera singola anziché multi-vista, talvolta non perfettamente fissa e qualità video variabile.

Le sequenze sono state selezionate in modo da coprire tutti e 10 i generi di danza presenti in AIST++ (4 clip per ognuno), e sono state rinominate secondo la convenzione gXX_yt_N, dove gXX indica il genere di danza e N un numero progressivo. Questi video non sono mai stati impiegati nella fase di addestramento, ma utilizzati esclusivamente come test set per la valutazione finale delle prestazioni in uno scenario realistico.



Figura 12, 13 e 14: Esempi di frame dal dataset YouTube

3.3 Registrazioni in tempo reale

Il terzo insieme di dati è costituito dalle sequenze acquisite tramite il sistema di riconoscimento in tempo reale sviluppato in questo progetto (descritto in dettaglio nel capitolo 7). Ogni sessione viene salvata nello stesso formato utilizzato per i dati estratti offline, in modo da poter essere analizzata per ulteriori verifiche pratiche o utilizzata come materiale a supporto della dimostrazione finale. Le registrazioni sono state acquisite tramite smartphone collegato al computer come webcam virtuale, e comprendono sia i keypoints estratti sia il video sorgente. Le registrazioni sono state effettuate presso Eleven Dance Studio¹, una scuola di danza che ha messo a disposizione i propri spazi e alcuni allievi per le riprese.



Figura 15 e 16: Due frame tratti dalle registrazioni in tempo reale

3.4 Conclusione

I tre insiemi di dati descritti, distinti per ruolo (addestramento, verifica della generalizzazione, dimostrazione), richiedono una rappresentazione uniforme dei dati in ingresso al modello. Il capitolo seguente descrive come questa rappresentazione viene estratta dai video originali.

¹ <https://www.instagram.com/eleven.dancestudio/>

Classificazione di stili di danza da video

4. Estrazione dei keypoints

Per ottenere una rappresentazione del movimento a partire dai video, sia quelli presi da YouTube sia quelli acquisiti dal vivo, è stato necessario definire una pipeline di estrazione dei keypoints bidimensionali. Questo capitolo descrive la scelta dello strumento di pose estimation utilizzato e la struttura della pipeline di estrazione.

4.1 Scelta dello strumento di pose estimation

Diversi strumenti sono stati presi in considerazione per l'estrazione dei keypoints dai video. Il lavoro che accompagna il dataset AIST++ utilizza OpenPose [14], producendo un file JSON per ciascun frame che viene poi unito nei file pickle finali. Per questo progetto sono stati invece valutati due strumenti più recenti: MediaPipe [15] e MMPose [16]. MediaPipe individua 33 keypoints, mentre MMPose supporta nativamente lo schema COCO a 17 keypoints, lo stesso adottato dal dataset AIST++ nei file keypoints2d. Per garantire piena compatibilità tra i dati del dataset di addestramento e quelli acquisiti successivamente, è stato scelto MMPose, un framework open source che rappresenta uno degli strumenti di riferimento più avanzati in questo ambito. In particolare, il framework gestisce l'estrazione in due fasi: dapprima rileva la presenza e la posizione della persona nel frame, circoscrivendola in una bounding box, e successivamente stima le coordinate dei 17 keypoints all'interno di quella specifica area. L'intero processo è stato eseguito su GPU per contenere i tempi di elaborazione.




Figura 17 e 18: A sinistra lo schema dei 17 keypoints COCO, a destra lo schema dei 33 keypoints del formato utilizzato da MediaPipe

4.2 Pipeline di estrazione

Per ciascun video, la pipeline di estrazione carica i singoli frame, li passa in batch al modello di pose estimation e restituisce, per ogni frame, le coordinate bidimensionali dei 17 keypoints COCO insieme al relativo punteggio di confidenza. Il risultato viene salvato in un file pickle strutturato in modo analogo ai file keypoints2d del dataset AIST++, cioè come un array di forma (numero di frame, 17, 3), dove l'ultima dimensione contiene le coordinate x, y e il punteggio di confidenza stimato dal modello.

Un aspetto critico emerso durante lo sviluppo riguarda la gestione del frame rate e della risoluzione dei video. Il dataset AIST++ è stato acquisito quasi interamente a 60 frame al secondo, e le poche sequenze con un frame rate leggermente diverso sono state uniformate a 60 fps dagli autori del dataset. Questo aveva inizialmente portato a considerare 60 fps come un valore costante all'interno

della pipeline di estrazione delle feature (descritta nel capitolo successivo), un'ipotesi che si è rivelata non valida non appena si è iniziato a lavorare con video YouTube, che hanno frame rate e risoluzione variabili. Per questo motivo ogni file estratto memorizza anche il frame rate, la larghezza e l'altezza del video, informazioni poi utilizzate per calcolare correttamente le grandezze che dipendono dal tempo, come velocità e accelerazione.

Per verificare la correttezza dell'estrazione sono stati realizzati diversi strumenti di visualizzazione: un'animazione che ricostruisce lo scheletro unendo i keypoints estratti (Figure 19 e 20), la visualizzazione della traiettoria di alcuni keypoints nel tempo (Figure 21 e 22) e la sovrapposizione dello scheletro animato al video originale (Figure 23 e 24). Questi strumenti sono stati utilizzati soprattutto in fase di debug, per verificare visivamente che le feature calcolate corrispondessero a quanto osservabile nel video, oltre che come supporto grafico alla presentazione dei risultati.




Figura 19 e 20: A sinistra un frame originale di un video; a destra lo stesso frame rappresentato tramite i keypoints estratti e lo scheletro ricostruito.




Figura 21 e 22: A sinistra un frame di un video; a destra lo stesso frame con disegnata la traiettoria della mano




Figura 23 e 24: Sovrapposizione dei keypoints e dello scheletro al video

4.3 Conclusione

La pipeline di estrazione descritta produce, per ciascun video, una sequenza di keypoints bidimensionali in un formato coerente sia per i dati di addestramento sia per quelli acquisiti successivamente. Il capitolo seguente descrive come queste coordinate vengono trasformate nelle feature numeriche utilizzate per la classificazione.

5. Estrazione delle feature

A partire dai keypoints bidimensionali, il sistema calcola per ciascuna sequenza un insieme di feature numeriche, utilizzate come input per il classificatore. Questo capitolo descrive dapprima la normalizzazione applicata ai keypoints, necessaria per rendere le feature confrontabili tra sequenze diverse, e successivamente le singole feature calcolate, organizzate secondo un framework ispirato alla Laban Movement Analysis [7].

5.1 Normalizzazione dei keypoints

Prima di calcolare qualunque feature, i keypoints di ciascuna sequenza sono stati normalizzati in due passaggi. Nella prima fase le coordinate vengono traslate in modo che il centro del bacino, calcolato come punto medio tra i due fianchi nel primo frame valido della sequenza, coincida con l'origine degli assi. Nel secondo passaggio le coordinate vengono scalate dividendole per la distanza massima osservata, lungo tutta la sequenza, tra il naso e la caviglia più distante tra le due.

Questa normalizzazione è necessaria perché i keypoints estratti dai video sono espressi in pixel, e la scala in pixel di una persona dipende da fattori come la distanza dalla telecamera o l'inquadratura. Esprimendo le feature in un'unità relativa alle proporzioni del corpo del ballerino ripreso, anziché in pixel assoluti, è possibile confrontare sequenze acquisite in condizioni molto diverse tra loro, come si è reso necessario confrontando le sequenze di AIST++ con i video YouTube.




Figura 25: Confronto prima e dopo la normalizzazione

5.2 Feature ispirate alla Laban Movement Analysis

Le feature utilizzate per descrivere il movimento sono state organizzate secondo le categorie proposte dalla Laban Movement Analysis (LMA) [7], un framework sviluppato dal coreografo e teorico del movimento Rudolf Laban nella prima metà del Novecento per descrivere in modo sistematico il movimento del corpo umano, inizialmente per la danza e il teatro e successivamente adottato anche in ambiti come la psicologia, la riabilitazione e, più di recente, la computer vision. La LMA descrive il movimento lungo quattro categorie complementari: Body, ovvero quali parti del corpo si muovono e come sono connesse tra loro; Effort, ovvero l'energia con cui il movimento viene eseguito, quanto risulta veloce, potente o fluido; Shape, ovvero come il corpo cambia forma nello spazio nel corso del movimento; Space, ovvero come il corpo si muove nello spazio circostante, ad esempio lungo traiettorie dirette o più libere.

Il presente lavoro non mira a riprodurre integralmente la LMA nella sua forma qualitativa originale, ma propone un insieme di descrittori computazionali ispirati a queste quattro categorie, calcolabili a partire da keypoints bidimensionali.

Una scelta trasversale a diverse feature riguarda l'aggregazione delle grandezze calcolate per ciascun frame in un singolo valore per sequenza. Per la maggior parte delle feature di Body e Shape, si è scelto di utilizzare media e deviazione standard, in modo da catturare sia la configurazione tipica sia quanto essa vari nel corso della sequenza, con due eccezioni: l'area del corpo, per cui si è preferito il massimo alla deviazione standard, così da catturare l'estensione massima raggiunta durante il movimento; e gli istogrammi angolari, che essendo già una distribuzione di frequenza non richiedono un'ulteriore aggregazione. Per le feature di Effort e per la feature di Space, che si ottengono calcolando quanto le posizioni cambiano da un frame al successivo (velocità, accelerazione), si è invece scelto di utilizzare la mediana, motivata da considerazioni generali sulla minore sensibilità ai valori estremi.

5.2.1 Body

La categoria Body è rappresentata dalla distanza di ciascuno dei 12 keypoints utilizzati (spalle, gomiti, polsi, fianchi, ginocchia e caviglie) dal centro del bacino, calcolata per ciascun frame e poi aggregata su tutta la sequenza tramite media e deviazione standard. Queste feature descrivono la configurazione posturale tipica del ballerino, cioè quanto le braccia e le gambe si estendano rispetto al centro del corpo, e quanto questa configurazione vari nel tempo.




Figura 26: Distanza del polso destro e della caviglia sinistra dal centro del bacino nel tempo, con i segmenti corrispondenti disegnati sullo scheletro e media indicata nel grafico

5.2.2 Shape

La categoria Shape raccoglie le feature che descrivono come il corpo cambia forma durante il movimento. Vengono calcolate l'area del bounding box che racchiude i 12 keypoints in ciascun frame, aggregata come media e come massimo lungo la sequenza, la distanza tra i due polsi e tra le due caviglie, aggregate come media e deviazione standard, e una distanza incrociata calcolata come media e deviazione standard tra la distanza del polso sinistro dalla caviglia destra e quella del polso destro dalla caviglia sinistra, pensata per catturare le torsioni del busto. A queste si aggiungono gli istogrammi degli angoli di gomiti e ginocchia, calcolati suddividendo l'intervallo tra 0 e 360 gradi in 8 sezioni e misurando la frequenza con cui l'angolo assume valori in ciascuna sezione lungo la sequenza. Questi istogrammi catturano quali configurazioni articolari il ballerino assume più frequentemente nel corso del movimento.




Figura 27: Area del corpo nel tempo, con il bounding box dei 12 keypoints evidenziato sullo scheletro e media e massimo indicati nel grafico.




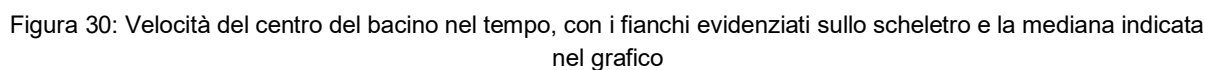
Figura 28: Angolo del gomito sinistro e destro nel tempo, con i relativi archi disegnati sullo scheletro, alla base del calcolo degli istogrammi

5.2.3 Effort

La categoria Effort descrive la componente energetica del movimento. Vengono calcolate la velocità e l'accelerazione di polsi e caviglie, e la velocità angolare di gomiti e ginocchia, tutte aggregate tramite mediana. Queste feature permettono di distinguere stili di danza dalla dinamica molto diversa pur in presenza di pose simili: uno stile esplosivo produce valori di accelerazione e velocità angolare sensibilmente più alti rispetto a uno stile più fluido.



La categoria Space descrive come il ballerino utilizza lo spazio circostante. È rappresentata da un'unica feature, la mediana della velocità del centro del bacino calcolata su coppie di frame distanti un secondo, che fornisce un'indicazione di quanto il ballerino si sposti nello spazio nel corso dell'esibizione, indipendentemente dai movimenti più locali già descritti dalle altre categorie.



Le feature descritte in questo capitolo, organizzate secondo le quattro categorie Body, Effort, Shape e Space, costituiscono l'input numerico della pipeline di classificazione. Il capitolo seguente ne descrive l'addestramento e i risultati ottenuti.

6. Addestramento e analisi dei risultati

Questo capitolo descrive la pipeline utilizzata per classificare lo stile di danza a partire dalle feature descritte nel capitolo precedente, la strategia adottata per la suddivisione dei dati tra train e test e infine l'analisi dei risultati ottenuti: le prestazioni sul test set di AIST++, la capacità di generalizzare su video acquisiti in condizioni diverse e un'analisi di interpretabilità tramite SHAP [17].

6.1 Pipeline di training

La classificazione utilizza un Random Forest, scelto per la robustezza su feature eterogenee. La pipeline applica in sequenza un'imputazione dei valori mancanti (SimpleImputer, strategia mediana, per gestire i frame con keypoints non rilevati) e il classificatore. Il modello è configurato con 300 alberi; gli altri iperparametri sono stati lasciati ai valori predefiniti di scikit-learn **Errore. L'origine riferimento non è stata trovata.** e un seed fisso è stato usato sia per il classificatore sia per la suddivisione dei dati, per rendere i risultati riproducibili.

Il dataset è stato suddiviso in training e test (80/20) tramite *GroupShuffleSplit*, raggruppando le sequenze per genere e numero di coreografia: AIST++ riutilizza infatti la stessa coreografia su ballerini e brani musicali diversi; quindi, sequenze che condividono la stessa coreografia (indipendentemente da chi la esegue o su quale musica) vengono trattate come un unico gruppo, che non può comparire sia in training sia in test. Questo evita che il modello impari a riconoscere la sequenza di movimenti specifica di una coreografia, invece dello stile di danza in generale.

6.2 Analisi dei risultati

L'analisi dei risultati ottenuti si articola in tre parti: le prestazioni del modello sul test set di AIST++, la sua capacità di generalizzare a video acquisiti in condizioni diverse, e un'analisi di interpretabilità tramite SHAP che permette di identificare quali feature contribuiscono maggiormente alle previsioni del modello.

6.2.1 Metriche sul test set di AIST++

Sul test set di AIST++ il modello raggiunge un'accuratezza complessiva del 89,72% e una Top-3 accuracy del 100,00%.

Stile	Precision (%)	Recall (%)	F1-score (%)
Break (BR)	90.62	87.88	89.23
House (HO)	77.78	93.33	84.85
Ballet Jazz (JB)	97.30	97.30	97.30
Street Jazz (JS)	92.11	97.22	94.59
Krump (KR)	100.00	78.26	87.80
LA style Hip-Hop (LH)	81.25	76.47	78.79
Lock (LO)	94.29	97.06	95.65
Middle Hip-Hop (MH)	75.00	84.00	79.25
Pop (PO)	86.96	90.91	88.89
Waack (WA)	100.00	91.30	95.45
Media (macro)	89.53	89.37	89.18




Figura 31: Confusion matrix delle 10 classi sul test set AIST++

6.2.2 Generalizzazione sul dataset YouTube

Nel dataset YouTube l'accuratezza scende dall'89,72% del test set interno al 42,50%, un calo marcato e coerente con quanto riportato dai lavori più direttamente comparabili in letteratura, dove i modelli allenati su AIST++ mostrano un degrado marcato e disomogeneo tra stili su dati esterni. La Top-3 accuracy si mantiene più alta (75,00%), indicando che lo stile corretto è quasi sempre tra le prime tre ipotesi del modello anche quando la previsione singola è sbagliata.

Stile	Precision (%)	Recall (%)	F1-score (%)
Break (BR)	60.00	75.00	66.67
House (HO)	0.00	0.00	0.00
Ballet Jazz (JB)	0.00	0.00	0.00
Street Jazz (JS)	33.33	50.00	40.00
Krump (KR)	60.00	75.00	66.67
LA style Hip-Hop (LH)	0.00	0.00	0.00
Lock (LO)	50.00	25.00	33.33
Middle Hip-Hop (MH)	0.00	0.00	0.00
Pop (PO)	66.67	100.00	80.00
Waack (WA)	44.44	100.00	61.54
Media (macro)	31.44	42.50	34.82

Tabella 3: Precision, recall e F1 per stile sul dataset YouTube

Va segnalato un limite statistico di questa valutazione: con solo 4 video per stile, ciascuna classe è rappresentata da un campione molto piccolo, e un singolo errore o successo sposta il risultato di quella classe di molti punti percentuali.

6.2.3 Interpretabilità tramite SHAP

Le decisioni prese da un modello di machine learning sono spesso difficili da interpretare: il modello si comporta come una *black-box* e non è immediato risalire a quali feature abbiano effettivamente pesato su una specifica previsione. Per questo motivo, per interpretare le decisioni del modello è stata condotta un'analisi SHAP (SHapley Additive exPlanations) [17], che attribuisce a ciascuna feature un contributo quantitativo alla previsione di ogni singolo campione, calcolato in modo esatto tramite TreeExplainer, sfruttando la struttura ad albero del Random Forest.

Le feature con il maggiore impatto complessivo (Figura 32) appartengono prevalentemente alle categorie Effort (velocità e accelerazione delle caviglie) e Body (distanza dei fianchi dal centro del bacino). Questo risultato è coerente con la natura del problema: distinguere gli stili di danza richiede sia di catturare quanto energicamente il corpo si muove (Effort), sia come le sue parti sono tipicamente configurate rispetto al centro (Body).

Il confronto tra i grafici beeswarm di due stili specifici, Middle Hip-Hop (Figura 33) e Street Jazz (Figura 34), rende evidente come la stessa feature possa influenzare stili diversi in direzioni opposte. In entrambi i casi, la velocità e l'accelerazione delle caviglie risultano tra le feature più influenti, ma con un effetto invertito: valori alti (in rosso) spingono la previsione verso Middle Hip-Hop, mentre per Street Jazz sono i valori bassi (in blu) ad avere impatto positivo sulla classe. Questo pattern è coerente con le caratteristiche note dei due stili: il Middle Hip-Hop si associa ad un uso più energetico delle gambe, mentre lo Street Jazz predilige un movimento più controllato e fluido.




Figura 32: Impatto e contributo delle prime 10 feature alle previsioni del modello




Figura 33: valori SHAP che illustrano il contributo delle feature alle previsioni del modello per lo stile Middle Hip-Hop




Figura 34: Valori SHAP che illustrano il contributo delle feature alle previsioni del modello per lo stile Street Jazz

6.3 Conclusione

I risultati presentati mostrano un'accuratezza solida sul test set interno di AIST++, ma un calo marcato su dati acquisiti in condizioni diverse, un limite condiviso anche dai lavori più direttamente comparabili in letteratura. Questi risultati si riferiscono a una classificazione su video già registrati: il capitolo seguente descrive come la stessa pipeline sia stata integrata in un sistema in grado di riconoscere lo stile di un ballerino dal vivo.

7. Sistema di riconoscimento in tempo reale

Questo capitolo descrive il sistema di riconoscimento in tempo reale, un'applicazione dimostrativa che riutilizza l'intera pipeline di classificazione descritta nei capitoli precedenti per riconoscere lo stile di un ballerino dal vivo tramite webcam. Vengono descritte l'architettura adottata per ridurre i tempi di attesa e il metronomo sincronizzato con i brani musicali.

7.1 Panoramica del sistema

Il sistema riutilizza l'intera pipeline descritta nei capitoli precedenti (stessa funzione di estrazione feature, stesso modello allenato), integrata in un'applicazione che acquisisce video da webcam, classifica lo stile del ballerino e avvia automaticamente un brano musicale coerente con lo stile riconosciuto. Il sistema registra inoltre l'intera sessione tramite un processo ffmpeg separato per la sovrapposizione dello scheletro sul video.

7.2 Architettura

Un'implementazione sequenziale del sistema (cattare 10 secondi di video, poi estrarre i keypoints su tutti i frame, poi estrarre le feature e classificare) richiederebbe di attendere l'intera durata di ciascuna fase una dopo l'altra: nei test preliminari, questo comportava un'attesa di molti secondi dopo la fine della registrazione, prima di ottenere un risultato.

Per ridurre questa attesa, il sistema separa la cattura e l'estrazione dei keypoints in due thread distinti, comunicanti tramite una coda: il thread principale cattura i frame e li inserisce in coda non appena disponibili; un altro thread preleva i frame dalla coda in piccoli gruppi ed esegue l'estrazione dei keypoints su di essi, in parallelo rispetto alla cattura successiva. Poiché la cattura è più rapida della stima della posa, la coda si riempie progressivamente durante i primi 10 secondi di registrazione: a titolo di esempio, a 7,8 secondi dall'inizio di una sessione reale (Figura 36) risultano 128 frame già elaborati e 40 ancora in coda. Superati i 10 secondi, la cattura si interrompe e il thread di elaborazione continua a svuotare la coda residua, questa volta senza nuovi frame in arrivo. Solo una volta che la coda è completamente svuotata vengono calcolate le feature e prodotta la classificazione. Il risultato è che, quando la registrazione termina, gran parte del lavoro di estrazione dei keypoints è già stata completata durante la cattura stessa: rimane da elaborare solo l'arretrato residuo, non l'intera sequenza, riducendo l'attesa a pochi secondi.

Il processo si articola quindi in quattro fasi: cattura ed elaborazione dei frame in parallelo durante i primi 10 secondi; solo elaborazione fino allo svuotamento della coda; estrazione delle feature e classificazione; e infine l'avvio del brano musicale associato allo stile riconosciuto.



Figura 35: Le fasi del sistema di riconoscimento in tempo reale, con la durata approssimativa di ciascuna.



Figura 36: Interfaccia del sistema durante la Fase 1 (cattura + elaborazione) a 7,8 dei 10 secondi di registrazione. Lo scheletro estratto dai keypoint è sovrapposto al video originale; le due barre in basso mostrano i frame ancora in coda (40) e quelli già elaborati (128)

7.3 Metronomo e riproduzione musicale

Per dare al ballerino un riferimento di tempo durante l'attesa, dalla cattura fino all'avvio del brano, un metronomo sintetico scandisce il tempo a un BPM fisso, calcolato come media dei BPM originali dei brani associati ai 10 stili (circa 115 BPM). Il metronomo viene avviato in un ulteriore thread separato, indipendente sia dalla cattura sia dalla stima della posa, e riproduce un suono a intervalli regolari dalla Fase 1 fino alla Fase 3: il ballerino ha così sempre un riferimento ritmico su cui muoversi, anche nei secondi in cui il sistema sta ancora elaborando e nessun brano è stato ancora selezionato.

Per evitare che il metronomo risultasse scollegato dal ritmo del brano che sarebbe poi partito, tutti i 10 brani sono stati a loro volta convertiti a questo stesso BPM comune (115), invece di lasciarli ciascuno al proprio tempo originale. Il BPM di ciascun brano è stato individuato con uno strumento online², e la conversione al tempo comune è stata effettuata con Audacity³. In questo modo il riferimento ritmico dato dal metronomo resta coerente con il brano, senza uno scarto percepibile nel passaggio dal click sintetico alla musica.

Il metronomo si interrompe automaticamente nell'istante in cui la classificazione produce un risultato, subito prima che parta il brano associato allo stile riconosciuto. Ciascun brano non parte dall'inizio, ma da un punto specifico scelto in anticipo per ogni stile: i brani sono stati così ritagliati per saltare le introduzioni ed entrare direttamente in una sezione riconoscibile ed energica, rendendo il momento in cui lo stile viene rivelato più immediato ed efficace.

7.4 Conclusione

Il sistema descritto riutilizza l'intera pipeline di classificazione in un contesto dal vivo, riducendo l'attesa percepita dall'utente tramite l'architettura a descritta. Il capitolo seguente analizza invece il costo computazionale e ambientale di alcune scelte metodologiche adottate lungo il percorso.

² <https://vocalremover.org/it/key-bpm-finder>

³ <https://www.audacityteam.org>

Classificazione di stili di danza da video

8. Sostenibilità computazionale

Nel machine learning, l'accuratezza è uno dei criteri più importanti con cui si giudica la qualità di un modello. Questo lavoro adotta invece anche una seconda lente di lettura, sempre più rilevante nella pratica odierna: il costo energetico e ambientale necessario per ottenere quell'accuratezza, misurato con la libreria open source CodeCarbon [19], a partire dalla potenza di CPU, GPU e RAM campionata durante l'esecuzione.

8.1 Il costo di una singola sessione

Il primo aspetto misurato è il costo di elaborare un singolo video di 10 secondi, la stessa durata usata nel sistema di riconoscimento in tempo reale (descritta nel capitolo precedente): cattura webcam, estrazione dei keypoints ed estrazione delle feature con classificazione.




Figura 37: Pipeline per un video di 10 secondi

Nel grafico, l'asse verticale elenca le tre fasi misurate, mentre l'asse orizzontale indica il tempo impiegato da ciascuna, in secondi. Accanto a ciascuna barra sono riportati l'energia stimata consumata (in Wh) e la potenza media corrispondente (in W). L'estrazione dei keypoints risulta la fase più costosa sia in energia (0,419 Wh) sia in potenza media (~111 W), coerente con l'uso intensivo della GPU per l'inferenza del modello di pose estimation. L'estrazione delle feature e la classificazione invece hanno un costo energetico trascurabile (0,001 Wh).

8.2 Il costo dell'addestramento

Il modello finale però non viene addestrato su un singolo video: il dataset di training comprende 1408 sequenze, per una durata totale di circa 5 ore e 13 minuti di contenuto video (18.776,8 secondi). A differenza del sistema in tempo reale, in questo caso l'estrazione dei keypoints non viene mai eseguita realmente: AIST++ fornisce già i file dei keypoints già estratti, evitando di dover rielaborare da capo tutti i video. Il suo costo (Figura 38) è stato quindi stimato a partire dalla misura sul singolo video di 10 secondi descritto in 8.1, assumendo che il costo cresca proporzionalmente alla durata del video elaborato.




Figura 38: Pipeline di training

Gli assi seguono la stessa convenzione della Figura 37 (fasi sull'asse verticale, tempo in secondi su quello orizzontale, energia e potenza media riportate accanto a ciascuna barra), con l'unica differenza dell'asse del tempo in scala logaritmica. Il costo stimato dell'estrazione dei keypoints sull'intero dataset supera infatti di alcune migliaia di volte quello di estrazione delle feature e training.

8.3 Confronto tra video intero e segmentazione

È stata confrontata la classificazione sull'intero video con una variante che divide ciascuna sequenza in 10 segmenti, classificati indipendentemente e ricombinati con voto di maggioranza, un approccio ispirato a Hamscher et al. [9] e discusso più in dettaglio nel capitolo 2 (sezione 2.3.2), a cui si rimanda per la descrizione completa del metodo; lo stesso schema di segmentazione e voto di maggioranza è illustrato in Figura 8. La segmentazione porta in questo progetto un guadagno di accuratezza marginale, da 89,72% a 91,13%, un risultato sensibilmente più contenuto dei circa 12 punti percentuali riportati in [9] sullo stesso tipo di confronto, verosimilmente per la diversa composizione dell'insieme di feature e per l'utilizzo di keypoint bidimensionali invece di tridimensionali.

Per quantificare se questo guadagno giustifichi la maggiore complessità, è stato misurato il costo computazionale delle due varianti. La misura comprende l'estrazione delle feature e il training, non la cattura webcam o l'estrazione dei keypoints, comuni a entrambe le varianti e quindi non informative per il confronto. I risultati mostrano che la segmentazione è circa 3 volte più costosa in termini di tempo ed energia, a fronte di un piccolo guadagno di accuratezza. Questo confronto ha motivato la scelta del video intero come configurazione finale.




Figura 39: Confronto tempo/energia/CO2 e scatter energia-accuratezza tra le due varianti

8.4 Conclusione

L'analisi di sostenibilità ha permesso di riconoscere che analizzare il video intero invece di segmentarlo comporta un vantaggio ambientale misurabile. Il capitolo finale riprende questi risultati insieme a quelli dei capitoli precedenti, discutendone i limiti principali e le possibili direzioni di sviluppo futuro.

Conclusioni

Questo lavoro ha affrontato il problema della classificazione dello stile di danza a partire da video, sviluppando una pipeline basata su pose estimation 2D e un insieme di feature interpretabili ispirate alla Laban Movement Analysis, classificate con un modello Random Forest. Il sistema raggiunge un'accuratezza sul test set interno di AIST++ di 89,72%, ma mostra, in linea con la letteratura più direttamente comparabile, un calo marcato quando valutato su video acquisiti in condizioni non controllate. L'integrazione in un'applicazione dimostrativa in tempo reale ha inoltre mostrato che la stessa pipeline può essere resa utilizzabile dal vivo, con un'attesa di pochi secondi grazie alla parallelizzazione delle fasi di cattura ed estrazione; infine, il confronto tra video intero e segmentazione ha mostrato che il guadagno di accuratezza offerto dalla segmentazione non giustifica il suo costo ambientale, circa tre volte superiore, motivando la scelta del video intero come configurazione finale.

Oltre ai risultati tecnici, questo lavoro ha rappresentato un percorso di apprendimento su più fronti: la gestione di un'intera pipeline di machine learning, la raccolta dei dati e la valutazione critica dei risultati, la necessità di mettere in discussione le proprie scelte metodologiche e la scoperta che la sostenibilità computazionale può diventare essa stessa un criterio decisivo nella scelta tra alternative progettuali, non solo una misura da riportare a posteriori.

Sviluppi futuri

Il limite più rilevante di questo lavoro riguarda la generalizzazione del modello a dati acquisiti in condizioni diverse da quelle controllate del dataset di addestramento. Una possibile direzione di sviluppo riguarda la rappresentazione stessa del movimento: questo lavoro ha scelto keypoints bidimensionali per garantire coerenza tra dati di addestramento e dati acquisiti in condizioni reali, ma questa scelta comporta anche una perdita di informazione sulla profondità e una maggiore sensibilità alle condizioni di ripresa della telecamera, un fattore che potrebbe contribuire al calo di prestazioni osservato. L'uso di keypoints tridimensionali potrebbe risultare meno influenzato dall'angolazione di ripresa e, di conseguenza, generalizzare meglio.

Infine, come accennato nell'introduzione, l'idea iniziale di questo lavoro era orientata alla generazione di coreografie piuttosto che alla loro classificazione, un ambito rivelatosi troppo complesso per l'ambito di una tesi di Bachelor. Le feature interpretabili sviluppate in questo lavoro potrebbero però offrire, in futuro, un punto di incontro tra i due ambiti: anziché generare movimento con modelli poco interpretabili (come quelli discussi nel Capitolo 2), si potrebbero usare queste feature per guidare i modelli generativi. In questo modo, il processo di creazione diventerebbe molto più trasparente e facile da controllare.

Bibliografia

- [1] S. Tsuchida, S. Fukayama, M. Hamasaki, M. Goto, "AIST Dance Video Database: Multi-genre, Multi-dancer, and Multi-camera Database for Dance Information Processing," in *Proc. 20th Int. Society for Music Information Retrieval Conf. (ISMIR)*, 2019.
- [2] B. Baker, T. Liu, J. Matelsky, F. Parodi, B. Mensh, J. W. Krakauer, K. Kording, "Computational kinematics of dance: distinguishing hip hop genres," *Frontiers in Robotics and AI*, 11:1295308, 2024.
- [3] R. Li, S. Yang, D. A. Ross, A. Kanazawa, "AI Choreographer: Music Conditioned 3D Dance Generation with AIST++," in *Proc. IEEE/CVF Int. Conf. Computer Vision (ICCV)*, 2021. [Online]. Dataset disponibile: https://google.github.io/aistplusplus_dataset/
- [4] L. Siyao, W. Yu, T. Gu, C. Lin, Q. Wang, C. Qian, C. C. Loy, Z. Liu, "Bailando: 3D Dance Generation by Actor-Critic GPT with Choreographic Memory," in *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR)*, 2022.
- [5] J. Tseng, R. Castellon, K. Liu, "EDGE: Editable Dance Generation From Music," arXiv:2211.10658, 2022.
- [6] J. Qu, "A dance movement quality evaluation model using transformer encoder and convolutional neural network," *Scientific Reports*, 14:32058, 2024.
- [7] S. Dewan, S. Agarwal, and N. Singh, "Laban movement analysis to classify emotions from motion," in *Proc. Tenth Int. Conf. on Machine Vision (ICMV 2017)*, 2018.
- [8] M. Turab, P. Colantoni, D. Muselet, A. Tremeau, "Dance Style Recognition Using Laban Movement Analysis," arXiv:2504.21166, 2025.
- [9] B. Hamscher et al., "Dance Style Classification using Laban-Inspired and Frequency-Domain Motion Features," arXiv:2511.20469, 2025.
- [10] S. Alexanderson, R. Nagy, J. Beskow, G. E. Henter, "Listen, Denoise, Action! Audio-Driven Motion Synthesis with Diffusion Models," *ACM Transactions on Graphics*, 42(4), 2023.
- [11] Y. Zhong, Y. Demiris, "DanceMVP: Self-Supervised Learning for Multi-Task Primitive-Based Dance Performance Assessment via Transformer Text Prompting," *Proc. AAAI Conference on Artificial Intelligence*, 38(9), 10270-10278, 2024.
- [12] M. Loper, N. Mahmood, J. Romero, G. Pons-Moll, M. J. Black, "SMPL: A Skinned Multi-Person Linear Model," *ACM Transactions on Graphics*, 34(6):1-16, 2015. [Online]. Available: <https://smpl.is.tue.mpg.de/>
- [13] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollar, C. L. Zitnick, "Microsoft COCO: Common Objects in Context," in *Proc. European Conf. Computer Vision (ECCV)*, 2014.
- [14] Z. Cao, G. Hidalgo, T. Simon, S.-E. Wei, Y. Sheikh, "OpenPose: Realtime Multi-Person 2D Pose Estimation using Part Affinity Fields," arXiv:1812.08008, 2018.
- [15] C. Lugaresi, J. Tang, H. Nash, et al., "MediaPipe: A Framework for Building Perception Pipelines," arXiv:1906.08172, 2019.
- [16] MMPose Contributors, "OpenMMLab Pose Estimation Toolbox and Benchmark," 2020. [Online]. Available: <https://github.com/open-mmlab/mmpose>
- [17] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," in *Advances in Neural Information Processing Systems 30*, I. Guyon et al., Eds. Curran Associates, Inc., 2017, pp. 4765-4774. [Online]. Available: <http://papers.nips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions.pdf>

- [18] F. Pedregosa et al., "Scikit-learn: Machine learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825-2830, 2011.
- [19] CodeCarbon, "CodeCarbon: Track and reduce CO2 emissions from your computing," [Online]. Available: <https://codecarbon.io>